

# Priorização de leads de tecnologia na Bahia

Atividade 01: o que é a base.    Atividade 02: o que eu fiz com ela.



Isnan Ferreira da Mota Santos



# O problema e a entrega

- **Quem usa:** o analista que escolhe quais empresas procurar.
- **Hoje:** filtra planilha à mão, sem critério registrado.
- **Entrega:** lista ordenada, com contato e motivo da posição.

Para montar essa lista, preciso do cadastro inteiro

Dados abertos de CNPJ da Receita Federal — público, atualizado uma vez por mês, baixado por arquivo, sem consulta em massa por API.

# Atividade 01 — as cinco tabelas usadas

| Tabela                | Linhas     | Tamanho  | O que ela fornece                       |
|-----------------------|------------|----------|-----------------------------------------|
| Estabelecimentos 0..9 | 73.366.147 | 5,01 GiB | atividade, município, situação, contato |
| Empresas 0..9         | 70.085.592 | 1,28 GiB | razão social e porte                    |
| Simples               | 50.396.768 | 294 MiB  | marcação de MEI                         |
| Cnaes                 | 1.359      | <1 MiB   | nome da atividade                       |
| Municipios            | 5.572      | <1 MiB   | nome do município                       |

- **6,57 GiB** baixados. O servidor limita cada conexão a 1,1 MiB/s; com quatro em paralelo, 3,2 MiB/s.
- Uma empresa tem vários estabelecimentos: por isso 73,4 milhões de estabelecimentos para 70,1 milhões de empresas.

# Atividade 01 — do cadastro nacional até a lista

| Etapa                | Filtro aplicado                | Estabelecimentos |
|----------------------|--------------------------------|------------------|
| Cadastro nacional    | —                              | 73.366.147       |
| Recorte geográfico   | UF = BA                        | 3.616.754        |
| Recorte de atividade | CNAE nas divisões 62 e 63      | 15.095           |
| Validação            | cinco regras — nenhum descarte | 15.095           |
| Lista final          | situação cadastral ativa       | <b>7.042</b>     |

- Os dois recortes tiram 99,98% da base. O que sobra é o universo de trabalho do analista.
- O último filtro é o que mais importa — e é o assunto de dois slides à frente.

# Atividade 01 — do que é feito o recorte

| CNAE  | Atividade                        | Empresas |
|-------|----------------------------------|----------|
| 6209  | suporte técnico e manutenção     | 3.604    |
| 6201  | desenvolvimento sob encomenda    | 2.511    |
| 6204  | consultoria em TI                | 2.278    |
| 6319  | portais e provedores de conteúdo | 1.688    |
| 6399  | outros serviços de informação    | 1.481    |
| 6311  | tratamento de dados e hospedagem | 1.348    |
| 6202  | software customizável            | 1.168    |
| 6203  | software não customizável        | 780      |
| 6391  | agências de notícias             | 237      |
| Total |                                  | 15.095   |

- Divisão 62, serviços de TI: **10.341** — 68%.
- Divisão 63, serviços de informação: **4.754**.
- A maior fatia é **suporte e manutenção**, não desenvolvimento. Isso muda a oferta que faz sentido.

# Atividade 01 — quantas ainda existem

| Situação | Empresas | %    |
|----------|----------|------|
| Ativa    | 7.042    | 46,7 |
| Baixada  | 5.821    | 38,6 |
| Inapta   | 2.091    | 13,9 |
| Suspensa | 132      | 0,9  |
| Nula     | 9        | 0,1  |
| Total    | 15.095   | 100  |

- **Metade do recorte não está ativa.**  
Ligar para a lista filtrada é perder o dia.
- O cadastro diz que a empresa existe, não que ela funciona.
- MEI é só 3,4% — eu esperava que fosse o ruído principal, e não é.
- Por isso o sistema ordena, em vez de apenas filtrar.

# Atividade 02 — o caminho do dado

arquivos compactados da Receita

```
|
|- 1. fatiar      1 GiB por vez
|- 2. ler         tudo como texto
|- 3. recortar    UF=BA, CNAE 62 e 63
|- 4. validar     5 regras
|- 5. enriquecer  porte e MEI
|- 6. contato     telefone, e-mail
|- 7. ordenar     só ativas, por critério
|
|-> universo tratado
|-> lista de leads
|-> evidência da execução
```

- **Fatiar:** os 5 GiB compactados de Estabelecimentos viram **16 GiB de texto** ao descompactar. Cada pedaço é filtrado e apagado antes do próximo.
- **Ler como texto:** preserva os zeros à esquerda do CNPJ.
- **Contato:** montado no fim, para a lista já sair acionável.
- Dois comandos reproduzem tudo, do download à planilha.

## Atividade 02 — as cinco validações

| Regra                        | Defeito que ela pega  | Reprovados |
|------------------------------|-----------------------|------------|
| Dígito verificador do CNPJ   | chave corrompida      | 0          |
| Situação cadastral conhecida | código fora da tabela | 0          |
| Atividade existe na CNAE     | código inexistente    | 0          |
| Data de abertura válida      | o vazio 00000000      | 0          |
| CNPJ sem repetição           | ligação duplicada     | 0          |

- Nenhuma linha caiu aqui: a base é bem formada.
- O corte de verdade veio da situação cadastral — e é ela que define quem entra na lista.

## Atividade 02 — como a lista é ordenada

| Ordem | Critério                     |
|-------|------------------------------|
| 1     | porte acima de microempresa  |
| 2     | empresa de pequeno porte     |
| 3     | não é MEI                    |
| 4     | tecnologia é a atividade-fim |
| 5     | é matriz, não filial         |
| 6     | mais de 3 anos de atividade  |
| 7     | tem nome fantasia            |

- **O primeiro critério manda**; os seguintes só desempatam.
- Estar ativa não ordena: é condição de entrada.
- Mudar a prioridade é mudar a ordem desta lista — uma linha, à vista de todos.

Empate remanescente: a mais antiga primeiro.

# Atividade 02 — a justificativa de cada lead

- O que ordena é o que aparece escrito: posição e motivo não divergem.
- É a última coluna da planilha, preenchida em todas as 7.042 linhas.

## Primeira linha da planilha

ABA — COMPUTADORES, SISTEMAS E SERVICOS LTDA — Salvador — telefone e e-mail  
porte acima de microempresa | não é MEI | tecnologia como atividade-fim | matriz | mais de 3 anos |  
nome fantasia

# O que o pipeline entrega

| Arquivo                  | Conteúdo                       | Linhas × colunas |
|--------------------------|--------------------------------|------------------|
| universo_tratado.parquet | recorte validado e enriquecido | 15.095 × 33      |
| leads_priorizados.csv    | a lista do analista            | 7.042 × 16       |
| evidencia.json           | contagens de cada etapa        | —                |

- **6.968 leads com telefone** (98,9%) e 6.904 com e-mail.
- Competência 2026-09 processada em 2,5 minutos — 8 na primeira vez, quando nada está em cache.

# Decisões e próximos passos

## Decidi

- Ativa virou condição de entrada.
- Contato entra na planilha; nada vai ao repositório.
- Prioridade por ordem declarada de critérios.

## Próximo

- Medir com o analista os 20 primeiros.
- Rever a ordem dos critérios pela oferta.
- Guardar em banco e expor consulta.