

Priorização de leads de tecnologia na Bahia

Transformar o cadastro público de CNPJ da Receita Federal em uma lista ordenada de empresas, com justificativa explícita para cada posição.

Analista comercial

quem sente a dor: monta a lista de prospecção à mão, toda semana

Quem abordar primeiro

a decisão que o sistema apoia

Se construirmos uma lista priorizada por CNAE usando os dados abertos da RFB com regra explícita de aderência, esperamos reduzir o tempo até uma lista utilizável e aumentar a pertinência dos contatos, em comparação com a filtragem manual de planilha.

Dados abertos de CNPJ da Receita Federal

- **Não há API de consulta em massa.** A distribuição é um compartilhamento Nextcloud por **WebDAV**. APIs por CNPJ servem para enriquecer, não para montar universo.
- **ZIP → CSV**, separador ;, **ISO-8859-1**, **sem cabeçalho**. Os nomes das colunas vêm do layout oficial.
- Atualização **mensal**; competências de 2025-03 a 2026-09.
- O **CNPJ não existe pronto**: vem quebrado em básico, ordem e dígito verificador.
- Município usa **código interno da RFB**, não IBGE. Salvador é 3849, não 2927408.

ARQUIVO	TAMANHO
Estabelecimentos1	326 MB
Empresas 0..9	1,28 GB
Simples	294 MB
Cnaes + Municipios	< 1 MB
Amostra processada	2,0 GB
Competência completa	7,23 GB

Recorte: **UF = BA** e CNAE divisões **62 + 63** — serviços de TI e serviços de informação. "Tecnologia" atravessa quatro seções da CNAE 2.0; o filtro é por prefixo de divisão, não por subclasse.

A base é impecável. O problema é semântico.

0

registros reprovados nas cinco validações,
incluindo dígito verificador

50,5%

do universo recortado está **baixado** —
empresa encerrada

19,9%

está inapta

SITUAÇÃO CADASTRAL	REG.	%
Baixada	487	50,47
Ativa	277	28,70
Inapta	192	19,90
Suspensa	9	0,93

O cadastro registra existência jurídica, não atividade econômica. Um filtro por CNAE devolveria 965 nomes, dos quais sete em cada dez são inúteis para prospecção.

É esta a evidência de que **filtro não basta** — e de que o valor do sistema está no ranqueamento, não na consulta.

Hipótese refutada: eu esperava MEI dominando o setor. É 1,5% — as ocupações permitidas ao MEI excluem desenvolvimento e consultoria em TI. O discriminador virou situação cadastral e porte.


Entrada real, saída estruturada, tudo em código

```
ZIP (latin-1, sem cabeçalho)
|
├─ transcodificar    latin-1 → UTF-8, em cache
├─ ler               scan_csv preguiçoso, tudo texto
├─ recortar          UF=BA ∧ CNAE 62|63
├─ validar           5 regras, marcação ≠ descarte
├─ enriquecer        porte, MEI, descrições
├─ remover pessoais  LGPD, antes de escrever
└─ priorizar         regra + justificativa
    |
    ├── universo_tratado.parquet
    ├── leads_priorizados.csv
    └── evidencia.json
```

VALIDAÇÃO	REPROV.
Dígito verificador do CNPJ (mód. 11)	0
Situação cadastral no domínio	0
CNAE existe em Cnaes.zip	0
Data parseável e não futura	0
CNPJ de 14 dígitos único	0

- **Reprodutível:** dois comandos, do download à saída.
- **Idempotente e retomável:** Range, escrita atômica em .part, cinco tentativas.
- **Nível 1:** regra explícita, sem ML. Cada lead carrega o motivo da posição.

Competência 2026-09 · 87 segundos



Alertas e correções durante a execução

- **corrigido** **77,6% sem porte.** Os básicos de Estabelecimentos1 têm só **10,3%** de interseção com Empresas1: o particionamento das duas tabelas é independente. Passei a ler as dez partições.
- **corrigido** **MEI deu 0%.** A RFB grava "00000000" em data ausente, não nulo — a condição de exclusão zerava tudo. Valor real: 1,5%.
- **tratado** Queda de conexão no download. Motivou a retentativa com retomada.

CHECKPOINT

O que avançou, o que travou, o que decidi

AVANÇOU

- Camadas **Fonte** e **Pipeline** implementadas e reproduzíveis.
- 277 leads ativos com score e justificativa por linha.
- Dado pessoal descartado antes de qualquer escrita.

TRAVOU

- **Viés da partição.** 2021 tem 147.576 aberturas; 2022 a 2026 somam ~120. A amostra não representa registros recentes — e empresa nova é lead de interesse. Causa não determinada.

DECIDI

- Situação ativa passa de pontuação a **critério eliminatório**.
- MEI foi rebaixado; **porte** assumiu o papel de discriminador.
- A camada de IA **continua sendo regra**: sem variável de operação ou faturamento, subir para ML exige outra fonte, não outro algoritmo.

PRÓXIMO PASSO

- Processar as dez partições e verificar se o corte temporal desaparece.
- Submeter os 20 primeiros leads ao analista e medir pertinência.